

Com base nos logs de execução fornecidos, este relatório apresenta uma comparação detalhada do desempenho da rede neural Multilayer Perceptron (MLP) aplicada ao dataset Iris, variando a quantidade de neurônios na camada oculta e a função de ativação.

1. Visão Geral do Experimento

Todos os modelos foram treinados sob as mesmas condições de reprodutibilidade: **Seed 42**, otimizador **Adam**, taxa de aprendizado 0.01, e o dataset Iris dividido em treino (70%), validação (14,7%) e teste (15,3%). O objetivo foi classificar três espécies de flores (Setosa, Versicolor e Virginica).

2. Tabela Comparativa de Resultados

Abaixo, os resultados consolidados das três arquiteturas testadas (Pequena, Média e Grande) com as funções de ativação ReLU, Sigmoid e Tanh:

Arquitetura (Input-Hidden-Output), Ativação, Acurácia Teste, Acurácia Treino, Acurácia Validação, Épocas (Early Stopping)

Arquitetura	Ativação	Acurácia Teste	Acurácia Treino	Acurácia Validação	Épocas
(4-3-3)	ReLU	95.65%	99.05%	86.36%	105
(4-3-3)	Sigmoid	95.65%	98.10%	86.36%	143
(4-3-3)	Tanh	95.65%	99.05%	86.36%	85
(4-16-3)	ReLU	95.65%	99.05%	86.36%	55
(4-16-3)	Sigmoid	95.65%	99.05%	86.36%	88
(4-16-3)	Tanh	91.30%	99.05%	86.36%	55
(4-64-3)	ReLU	95.65%	99.05%	86.36%	55
(4-64-3)	Sigmoid	95.65%	99.05%	86.36%	69
(4-64-3)	Tanh	91.30%	99.05%	86.36%	41

3. Análise dos Resultados

A. Influência da Função de Ativação

- ReLU: Demonstrou ser a mais consistente em todas as arquiteturas, mantendo 95.65% de acurácia no teste com convergência rápida, especialmente na arquitetura média (55 épocas).
- Sigmoid: Exigiu um número significativamente maior de épocas para convergir, especialmente no modelo pequeno (143 épocas), embora tenha atingido a mesma acurácia final de 95.65%.
- Tanh: Apresentou o pior desempenho nas arquiteturas média e grande, com uma queda na acurácia de teste para 91.30%, apesar de manter altas taxas no treino.

B. Impacto da Complexidade do Modelo (Neurônios)

- **Eficiência da Arquitetura Pequena:** Surpreendentemente, com apenas 3 neurônios, o modelo conseguiu atingir a mesma acurácia de teste (95.65%) que modelos maiores, embora precise de mais tempo de treinamento.
- **Velocidade de Convergência:** O aumento de 3 para 16 neurônios (Média) reduziu o tempo de treino pela metade no caso da ReLU (de 105 para 55 épocas).
- **Risco de Overfitting:** Nos modelos de maior complexidade (64 neurônios), os logs apontam explicitamente a ocorrência de overfitting para as funções Sigmoid e Tanh, indicando que o modelo começou a memorizar os dados de treino em vez de generalizar.

C. Diagnóstico de Generalização

A maioria dos modelos apresentou um gap de acurácia de aproximadamente 0.0340 entre o treino e o teste, o que é considerado um sinal de bom ajuste e generalização para este dataset específico. A exceção foram os modelos com ativação Tanh de maior porte, onde o gap foi maior (0.0774), indicando uma generalização inferior.

4. Conclusão

O modelo MLP (4-16-3) com ativação ReLU destaca-se como o mais equilibrado. Ele oferece uma excelente precisão (95.65%), convergência rápida (55 épocas) e estabilidade superior em comparação com as ativações Tanh e Sigmoid. Embora o modelo "Pequeno" seja eficaz, a arquitetura média provou ser mais eficiente em termos de tempo computacional sem comprometer a integridade dos resultados.